

题 目： 联合单目深度估计的深度图像超分辨率重建算法研究

学院： 软件学院 专业： 软件工程 学生姓名： 学号：

一、项目背景

1. 项目来源

人类对立体场景的感知包含了二维的外观（如颜色、纹理等）信息和三维的深度信息。随着人工智能的发展，自动驾驶、三维重建、人机交互等成为非常热门的研究领域，这些领域都依赖于高精度、高质量的深度信息^{[1][2]}。近年来，便携式消费级深度相机（如 ASUS Xtion 和 Mesa SwissRanger）等新型 3D 传感器的问世和普及，以及微软推出价格低廉的 Kinect 等，为主动地、快速地获取场景深度信息提供了极大便利，因而受到了学术界和工业界的广泛关注^[3]。

深度相机向目标场景发射特定光，然后通过接收反射光来快速实时地计算场景深度。按照工作原理，深度相机可划分为基于时间调制原理的飞行时间相机（Time of Flight, TOF）和基于结构光原理的相机（如 Kinect）两种类型。但是，由于当前成像技术的限制，深度相机拍摄的深度图像分辨率普遍较低，如微软 Kinect 1.0 的深度图分辨率仅为 320×240，Kinect 2.0 的深度图分辨率也仅仅为 512×424，无法与高分辨率的彩色图像相匹配。面对应用领域对高质量深度图像的迫切需求，如何提高深度相机所摄深度图像的空间分辨率成为一个亟待解决的问题。当前通过硬件设施来提高深度图像的空间分辨率，成本消耗较高，且还存在着一些技术瓶颈。而深度图像超分辨率重建技术是在深度相机硬件系统条件不变的前提下，利用重建算法恢复出图像的高频信息，并有效抑制随机噪声以及成像过程中的模糊现象，重建出高质量的高分辨率深度图。深度图像超分辨率重建技术，已经成为计算机视觉和图像处理领域的研究热点。

目前，深度图像超分辨率重建技术按照是否需要训练分为非学习式超分辨率重建算法和学习式超分辨率重建算法两类。非学习式超分辨率重建算法又可分为基于滤波的方法和基于优化的方法。学习式超分辨率重建算法的核心是通过在数据集上训练学习得到高层特征信息，并将高层特征信息映射成为超分辨率图像。

近些年，随着深度学习技术的快速发展，基于学习式的超分辨率重建技术取得了巨大进展。本项目来源于北京交通大学计算机与信息技术学院信息科学研究所的课题研究项目，以基于学习的超分辨率重建算法为基本方法，通过教师-学生网络搭建彩色-深度图像对之间的映射关系，借助全监督或自监督的深度估计网络进一步提高深度图像超分辨率重建的精度。

2. 项目意义

深度图像超分辨率重建是近年来计算机视觉和图像处理等领域的研究热点，不仅具有

重要的理论意义，而且在实际应用中也有着迫切的需求。

- (1) 在游戏领域，通过体感周边设备来获取玩家的姿态动作，进行人机交互操作，如果用超分辨率重建技术增强深度数据的分辨率和质量，有利于提高姿态识别率，进而大大提升玩家的游戏体验。
- (2) 在三维重建方面，对于深度相机获取的点云数据，利用超分辨率重建技术提高它的密集度和精度，从而建模出更具真实感的三维物体表面模型，促进三维重建在生物医学、视频监控、刑事案件分析、增强现实等领域的应用。
- (3) 在无人驾驶方面，利用深度信息来确定车辆的位置，深度图像超分辨率重建能帮助车辆获得更高的定位精度，同时进行更准确的环境描述和避障操作。

深度图像超分辨率重建相关技术的发展和成熟，全面促进了其在各个计算机视觉领域的深入应用，同时也给未来的研究工作提出了更高更新的要求。

3. 项目的研发现状

由于同场景的彩色图像与深度图像在结构上具有相似性，因而高分辨率的彩色图像可以为深度图像的超分辨率重建提供先验信息^{[4][5]}。但彩色图像与深度图像的边缘并非一一对应的，这种不一致性可能会在重建过程中引入纹理复制等问题。而单目场景深度信息估计就是要找到一个场景从彩色图像到深度信息的映射模型。近年来基于学习的方法通过设计良好的网络从数据中自动地学习如何恢复深度图并取得了很大进展^[6]。同时，深度学习以全监督方式在深度估计任务上也取得了良好的性能^[7]。本项目旨在建立一个教师-学生模型，通过教师网络在深度估计任务上学习彩色图像与深度图像的映射关系，然后利用教师模型学习到的“知识”帮助学生网络进行深度图像的超分辨率重建，从而达到更好的重建效果。

3.1. 学习式超分辨率重建算法

近年来，基于深度学习的方法在深度图像超分辨率重建领域的应用越来越广，按照是否利用纹理图像的引导信息大致可分为两类：单深度图像超分辨率算法和纹理图像引导的深度图像超分辨率算法^[8]。与图像超分辨率算法类似，单深度图像超分辨率算法通过构建卷积神经网络，学习从低分辨率深度图像到高分辨率深度图像的非线性映射关系，实现深度图像的超分辨率重建；基于纹理图像引导的深度图像超分辨率算法通常采用上采样或者下采样的方式，获取丰富的层次特征，利用对应尺度下纹理图像提供的引导信息，引导深度图像的重建过程，如：Hui 等^[9]构建了金字塔结构，输入的低分辨率深度图像经逐级采样后得到多尺度的特征表示，再融合对应尺度的纹理特征；Guo 等^[10]采用 U-Net 结构对插值后的深度图像进行编码，在解码过程中融合对应尺度的纹理特征。这两种特征融合结构以串联方式从低尺度到高尺度地逐步重建高分辨率的深度图像，均可以提取丰富的层次特征信息，却未能有效利用多尺度特征间的关联性进行特征融合。

3.2. 深度学习下的单目深度估计

现在普遍认为，当前所广泛使用的深度学习概念最早由 Hinton 在 2006 年提出，而深度学习真正成为学术界与产业界的热点是在 2012 年 Hinton 团队构建的 CNN 网络 AlexNet 以极大优势获得 ImageNet 图像识别比赛第一名后。从此，各种神经网络结构层出不穷，对于深度学习的研究也炙手可热。

2014 年，Eigen 团队^[11]首次利用卷积神经网络对单目图像进行深度估计，他们设计了一种包含两个尺度的卷积神经网络结构，将整个深度估计过程分为两步：(1) 在整幅图像上对场景全局深度的粗估计；(2) 通过图像局部特征优化粗估计深度图的精估计。这一方法获得了相当精确的深度估计结果并开创了深度学习在单目图像深度估计领域的先河。

在此之后，不少研究人员在 Eigen 团队工作的基础上，通过设计不同的神经网络结构、使用新的约束条件与损失函数对单目图像的深度估计进行优化改进。Eigen 团队^[12]于 2015 年将深度估计、表面法线预测和语义标注三个任务统一在一个三级的神经网络中，并将结果的分辨率提升至输入图像分辨率的一半。Grigorev 等^[13]将长短期记忆（LSTM）用于循环网络以获取图像全局信息，将其与一般的卷积神经网络混合使用实现了端到端的单目图像深度估计。Laina 等^[14]采用了更深的残差网络并使用小卷积代替大卷积来实现上采样，使得深度估计更为高效，并且提出了新颖的损失函数，从而可以得到更好的结果。Cao 等^[15]将原本连续的图像深度离散化为一定深度范围的类别，并将深度估计问题转化为分类问题，使用全卷积的深度残差网络实现分类，最后使用条件随机场优化结果得到最终的深度估计值。上述方法在网络的训练阶段都需要图像的参考深度，是监督型的学习。

3.3. 面向视觉智能的教师 - 学生网络

近些年深度神经网络几乎在各个领域都取得了巨大的成功。然而，这些深度模型在尺寸上过于巨大，造成了巨大的计算开销，致使模型难以部署和落地。除此之外，模型的表现也高度依赖于大量的标注数据。为了使模型得到更加高效的训练和应对标记数据不足的难题，由 Hinton 在 2015 年提出的知识蒸馏(KD)被用来迁移从一个模型到另一个模型学习到的知识。这个过程也经常被描述为 Student-Teacher(S-T) 学习框架。

知识蒸馏目前已经被广泛的应用在了从一个网络到另一个网络的信息转移上。知识蒸馏主要被应用在模型压缩和知识迁移这两个领域，对于模型压缩，一个较小的学生模型被训练来模仿一个预先训练好的较大的模型。尽管知识和任务种类多样，但是 S-T 框架是他们的一个相同点，其中提供知识的模型被称作 teacher，学习知识的模型被称作 student。知识蒸馏方法已经应用于视觉智能、语音识别、自然语言处理等多个领域。

截止到 2020 年 12 月 13 日，Hinton 等人的 KD 已经被引用 4955 次。在视觉领域，不少研究人员在传统 KD 的基础上进行了研究。Tian 等^[16]指出原始 KD 不适合跨模态蒸馏的情况，如将图像处理网络(处理 RGB 信息)的表示/特征迁移到深度处理网络(处理 depth 信息)。Mirzadeh S-I 等^[17]指出当教师与学生的模型大小差距太大时，KD 会失效，学生网络

的性能会下降，因而在教师网络和学生网络之间引入了助教网络。Jin 等^[18]受课程学习启发，并且知道学生和老师之间的差距很大导致蒸馏失败，提出路由约束提示学习。在模型压缩中，由于模型蒸馏可以用于任意网络而被广泛研究，并应用于具体的视觉计算任务之中。

二、项目内容、项目目标与拟解决的关键问题

1. 项目内容

本项目以深度图像超分辨率重建为基本任务，联合深度估计，以期两个任务互相促进，进而获得更加优异的重建精度。主要包括：

- (1) **模型设计**：单目深度估计在输出结果分辨率方面的需求与深度图像超分辨率重建算法的目的相契合，而基于深度学习的单目深度估计可以学习到彩色图像和深度图像不同模态之间的映射特征，可以从高维度指导学习式深度图像超分辨率重建算法合理地利用彩色图像的先验信息。基于教师-学生网络的设计理念，设计新的子网络与网络结构，融合特征，提出一种联合深度估计的深度超分辨率重建模型。
- (2) **数据准备**：利用对比论文提供的数据集集成深度图像超分辨率重建的训练数据、验证数据与测试数据。目前深度图像超分辨率重建的 RGB-D 数据集有 MIDDLEBURY DataSet，单目深度估计方法主要基于 KITTI、NYU Depth 和 Make3D 等数据集。
- (3) **实验评估**：使用模型，基于已有数据集，进行实验评估，并与其他能完成该任务的模型进行对比。
- (4) **分析总结**：通过消融研究验证不同模块对重建精度、抑制噪声等不同性能的影响，进行分析和总结。

2. 项目目标

设计和编码实现完整的网络架构进行深度图像的超分辨率重建，通过借助全监督或自监督的深度估计网络进一步提高深度图像超分辨率重建的精度，通过教师-学生网络搭建彩色-深度之间的映射关系。预期网络架构图如图 1 所示。

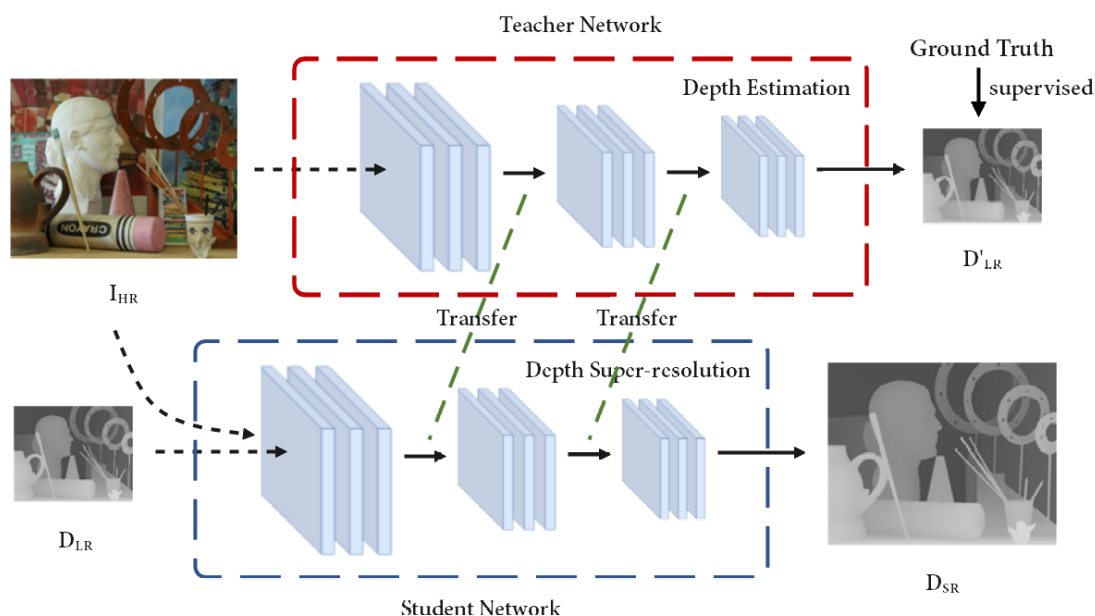


图 1 预网络期架构图

3. 拟解决的关键问题

3.1. 纹理转移和深度流失的消除

深度图像的边缘反映了目标物体的几何形状，而彩色图像是对场景的纹理和结构信息的表达，因此，深度图像的边缘大多对应了彩色图像中的目标边缘而不是纹理边缘，这意味着深度图像和彩色图像间的共生关系并不总是存在的。当用彩色图像来引导深度图像重建时，违背共生关系的重建区域会出现纹理转移或深度流失两种失真。

当目标表面具有丰富的彩色纹理细节时（深度连续而彩色不连续），共生性的使用会导致纹理转移，即物体表面的纹理细节会从彩色图像复制到深度图像中，使本应该连续的深度出现了不连续的间断；当不同深度的相邻目标具有相同的颜色（深度不连续而彩色连续），共生性的使用会导致深度流失，即本应该出现的深度边缘消失了。

对于彩色引导下的深度图像超分辨率重建方法而言，纹理转移和深度流失是不容忽视的问题，不准确的深度信息会使得后续应用难以开展。当前基于深度学习的方法对这方面的研究较少，如何设计特定的网络结构来解决彩色引导下深度重建的纹理转移和深度流失问题，是当前迫切需要解决的一个关键任务。

3.2. 深度估计与深度超分辨率重建的关联性问题

深度信息作为一个重要的基本元素而被广泛应用于众多计算机视觉领域。然而，由于深度相机的成像限制，高质量和高分辨率的深度图通常难以直接获得，因此有效的深度图像超分辨率重建技术就显得尤为重要。通常，同场景的高分辨率彩色图像可以弥补低分辨率的深度图像缺失的高频信息，他们在结构上具有较强的相似性，因此，现有的大部分深度图像超分辨率重建技术以彩色信息作为引导来恢复退化的深度图像。另一方面，深度图像的边缘大多对应了彩色图像中的目标边缘而不是纹理边缘，即深度图像和彩色图像间的共生关系并不总是存在的，这种不一致性可能会在重建的过程中造成纹理复制等问题，目前尚没有针对这一问题很好的解决办法。而单目场景深度信息估计就是要找到一个场景从彩色图像到深度信息的映射模型，同时由于深度估计任务的网络为感知场景全局信息而使用一系列池化和降采样操作，估计的深度图像分辨率通常较低。受上述分析的驱动，我们希望通过深度估计建立彩色图像与深度图像的映射关系，并将深度估计学习到的“知识”通过迁移学习的方法帮助低分辨率的深度图像进行超分辨率重建，从而达到更好的重建效果。探究和明确深度估计与深度超分辨率重建两个任务之间的关联性是本项目研究的关键问题。

三、拟采取的解决方案及可行性分析

1. 理论基础

（1）深度图像超分辨率重建

由于 LR 深度图像包含较少高频信息，同场景的 HR 彩色图像包含较多与其相关的高频信息，因此可以通过同场景 HR 彩色图像引导 LR 深度图像超分辨率重建以获得更优的重建结果。

在场景目标的边缘与轮廓上彩色图像和对应的深度图像具有很强的结构一致性，如图 2 中红色部分，两者都在梯形区域表现出了一致的边缘结构。彩色图像可以为深度图像超分辨率重建提供很多有用的信息，从而帮助深度图像在超分辨率重建过程中的结构恢复，提升超分辨率重建的质量。另一方面，彩色图像的纹理信息不一定会体现在深度图像上，如图 2 中绿色矩形区域，在彩色图像上具有较多的纹理变化，然而体现在深度图像上并没有对应的纹理结构。




图 2 深度图像和彩色图像的纹理结构

（2）多尺度特征

人类的视觉处理图像信息时是从不同尺度上进行的，因此有很多图像处理算法中均采用多尺度特征提取并融合的方法，以便获得各个尺度上更丰富的信息。而低分辨率图像的捕获系统可以视为图像的降质模型，在这一过程对场景中的物体造成的影响是不同的，尤其是结构精细和微小的物体。这就需要利用多尺度信息来增强特征表示的能力，从而精确地恢复每个深度区域。

（3）注意力机制

Attention 源于人类视觉系统，当人类观察外界事物的时候，一般不会把事物当成一个整体去看，往往倾向于根据需要选择性的去获取被观察事物的某些重要部分。同理，注意力机制可以帮助模型对输入的每个部分赋予不同的权重，抽取出更加关键及重要的信息，使模型做出更加准确的判断，同时不会对模型的计算和存储带来更大的开销。

（4）知识蒸馏

Hinton 在 2015 的工作中首次提出了知识蒸馏（暗知识提取）的概念，通过引入与教师网络（复杂、但推理性能优越）相关的软目标作为损失的一部分，以引导学生网络（精简、

低复杂度）的训练，从而实现知识迁移。

2. 拟采用的技术路线

在本次毕业设计（论文）中，针对不同部分的内容，拟采用的研究方法不同：

- （1） 在项目背景、项目意义、可行性分析和研究现状分析方面，使用现有文献进行分析，阅读国内外相关任务主流算法和算法性能较高的论文，总结当前研究的进展、技术路线和发展趋势，分析现有工作中流行的网络结构及不同模块对网络性能的影响。
- （2） 在算法原理和网络架构设计方面，拟对两个任务采用不同的网络设计方法，具体如下：

对于深度图像超分辨率重建网络，将在文献调研的基础上选择合适的骨干网络，对拟解决问题的产生原因和相关工作中所设计模块的作用机理进行分析，并实现重要算法，直观理解其作用机理和实验效果，从而选择合适的模块和架构设计。

对于单目深度估计任务，由于研究的重点在于深度图像的超分辨率重建任务，本项目拟采用现有的单目深度估计网络，通过对比分析不同网络的性能与架构，最终设计合适的约束关系（如教师 - 学生模型）与深度图像超分辨率重建网络形成完整的网络架构并实现。

网络将基于 Pytorch 实现，通过 GPU 加速训练。

- （3） 在模型的训练和测试方面，通过逻辑推理设计合适的损失函数，在不断训练和调试的过程中，确定最优的网络架构和训练方法，以期获得更高的重建精度。
- （4） 在算法的性能方面，拟通过消融研究的方法验证不同模块对模型重建精度、抑制噪声等不同性能的影响，从而消除模型中的冗余参数，降低复杂度。
- （5） 在结论方面，拟采用对比评估与辩证的思维，对现有算法进行分析，对项目的完成度进行探讨，并对本次设计做出总结与展望。

3. 可行性分析

- （1） 学习式超分辨率重建算法

基于深度学习的超分辨率重建算法的核心 通过大量的训练样本数据信息获取更多、更有价值的特征，建立关于低分辨率和超分辨率图像之间的映射关系，通过获取的映射关系重建超分辨率深度图。在彩色图像引导的深度图像超分辨率重建方面，现已经存在较多研究验证了多尺度特征和注意力机制等技术在深度图像超分辨率重建过程中的有效性。

- （2） 深度学习下的单目深度估计

深度学习在单目深度估计任务上取得了良好的性能。本项目拟采用现有的网络架构完成研究中的深度估计，根据监督方式的不同，现存研究主要分为全监督的单目深度估计和自监督的单目深度估计，自监督单目深度估计在视频序列等数据集上取得了可比的性能。目前，单目深度估计任务主要采用 Encoder-Decoder 架构作为网络骨干。下表为基于深度

学习的单目深度估计方法最新研究^[19]的性能表现。

表 1 AdaBins 在不同数据集上的性能

数据集	$\delta_1 \uparrow$	$\delta_2 \uparrow$	$\delta_3 \uparrow$	$REL \downarrow$	$RMS \downarrow$	$\log_{10} \downarrow$
NYU Depth	0.903	0.984	0.997	0.103	0.364	0.044
KITTI	0.964	0.995	0.999	0.058	0.190	0.088

（3） 面向视觉智能的教师 - 学生网络

现有的关于知识蒸馏方法的研究主要使用教师模型和学生模型来处理相同的任务，如教师和学生均用于图像分类、语义分割等。而最新的有关研究在图像重建和去雾两个任务探究了教师通过不同任务帮助学生网络学习的可行性及方法。Hong 等^[20]提出一种基于知识蒸馏的图像去雾网络。该方法先使用干净图像训练一个自编码网络作为 teacher 网络；然后将去雾网络作为 student 网络，并使用 teacher 网络挖掘的干净图像的隐含特征和重建信息来指导有雾图像到干净图像的映射。这一研究为研究知识蒸馏在处理不同任务的模型间进行知识迁移提供了范例。

主要参考文献：

1. Xincheng Ye, Baoli Sun, Zhihui Wang, Jingyu Yang, Rui Xu, Haojie Li, and Baopu Li. Pmbanet: Progressive multi-branch aggregation network for scene depth super-resolution. IEEE Trans. Image Process., 29:7427–7442, 2020.
2. Xincheng Ye, Baoli Sun, Zhihui Wang, Jingyu Yang, Rui Xu, Haojie Li, and Baopu Li. Depth super-resolution via deep controllable slicing network. In MM ' 20: The 28th ACM International Conference on Multimedia, Virtual Event / Seattle, WA, USA, October 12–16, 2020, pages 1809–1818. ACM, 2020.
3. Xibin Song, Yuchao Dai, Dingfu Zhou, Liu Liu, Wei Li, Hongdong Li, and Ruigang Yang. Channel attention based iterative residual learning for depth map super-resolution. In 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition, CVPR 2020, Seattle, WA, USA, June 13–19, 2020, pages 5630–5639. IEEE, 2020.
4. Yifan Zuo, Qiang Wu, Yuming Fang, Ping An, Liqin Huang, and Zhifeng Chen. Multi-scale frequency reconstruction for guided depth map superresolution via deep residual network. IEEE Trans. Circuits Syst. Video Technol., 30(2):297–306, 2020.
5. Yang Wen, Bin Sheng, Ping Li, Weiyao Lin, and David Dagan Feng. Deep color guided coarse-to-fine convolutional network cascade for depth image super-resolution. IEEE Trans. Image Process., 28(2):994–1006, 2019.
6. Xiao Gu, Yao Guo, Fani Deligianni, and Guang-Zhong Yang. Coupled real-synthetic domain adaptation for real-world deep depth enhancement. IEEE Trans. Image Process., 29:6343–6356, 2020.
7. Chaoqiang Zhao, Qiyu Sun, Chongzhen Zhang, Yang Tang, and Feng Qian. Monocular depth estimation based on deep learning: An overview. CoRR, abs/2003.06620, 2020.
8. Xibin Song, Yuchao Dai, and Xueying Qin. Deeply supervised depth map super-resolution as novel view synthesis. IEEE Trans. Circuits Syst. Video Technol., 29(8):2323–2336, 2019.

9. Tak-Wai Hui, Chen Change Loy, and Xiaoou Tang. Depth map superresolution by deep multi-scale guidance. In Computer Vision - ECCV 2016 - 14th European Conference, Amsterdam, The Netherlands, October 11-14, 2016, Proceedings, Part III, volume 9907 of Lecture Notes in Computer Science, pages 353–369. Springer, 2016.
10. Chunle Guo, Chongyi Li, Jichang Guo, Runmin Cong, Huazhu Fu, and Ping Han. Hierarchical features driven residual learning for depth map super-resolution. IEEE Trans. Image Process., 28(5):2545–2557, 2019.
11. David Eigen, Christian Puhrsch, and Rob Fergus. Depth map prediction from a single image using a multi-scale deep network. In Advances in Neural Information Processing Systems 27: Annual Conference on Neural Information Processing Systems 2014, December 8-13 2014, Montreal, Quebec, Canada, pages 2366–2374, 2014.
12. David Eigen and Rob Fergus. Predicting depth, surface normals and semantic labels with a common multi-scale convolutional architecture. In 2015 IEEE International Conference on Computer Vision, ICCV 2015, Santiago, Chile, December 7-13, 2015, pages 2650–2658. IEEE Computer Society, 2015.
13. Aleksei Grigorev, Feng Jiang, Seungmin Rho, Worku Jifara Sori, ShaohuiLiu, and Sergey Sai. Depth estimation from single monocular images usingdeep hybrid network.Multim. Tools Appl., 76(18):18585–18604, 2017.
14. Iro Laina, Christian Rupprecht, Vasileios Belagiannis, Federico Tombari, and Nassir Navab. Deeper depth prediction with fully convolutional residual networks. In Fourth International Conference on 3D Vision, 3DV 2016, Stanford, CA, USA, October 25-28, 2016, pages 239–248. IEEE Computer Society, 2016.
15. Yuanzhouhan Cao, Zifeng Wu, and Chunhua Shen. Estimating depth frommonocular images as classification using deep fully convolutional residualnetworks.IEEE Trans. Circuits Syst. Video Technol., 28(11):3174–3182,2018.
16. Yonglong Tian, Dilip Krishnan, and Phillip Isola. Contrastive representa-tion distillation.CoRR, abs/1910.10699, 2019.
17. Seyed-Iman Mirzadeh, Mehrdad Farajtabar, Ang Li, and HassanGhasemzadeh. Improved knowledge distillation via teacher assistant: Bridg-ing the gap between student and teacher.CoRR, abs/1902.03393, 2020.
18. Zhicheng Fang, Xiaoran Chen, Yuhua Chen, and Luc Van Gool. Towards good practice for cnn-based monocular depth estimation. In IEEE Winter Conference on Applications of Computer Vision, WACV 2020, Snowmass Village, CO, USA, March 1-5, 2020, pages 1080–1089. IEEE, 2020.
19. Shariq Farooq Bhat, Ibraheem Alhashim, and Peter Wonka. Adabins: Depthestimation using adaptive bins.CoRR, abs/2011.14141, 2020.
20. Ming Hong, Yuan Xie, Cuihua Li, and Yanyun Qu. Distilling image dehazing with heterogeneous task imitation. In 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition, CVPR 2020, Seattle, WA, USA, June 13-19, 2020, pages 3459–3468. IEEE, 2020.

毕业设计（论文）进度安排：

序号	毕业设计（论文）各阶段内容	时间安排	备注
1	明确深度图像超分辨重建任务的核心关键问题，探究高分辨率彩色图像在深度图像超分辨重建任	2020. 10. 21 --2020. 11. 21	

	务中的作用，分析深度图像超分辨率重建过程中边缘模糊、伪影等现象产生的原因		
2	明确深度估计与深度图像超分辨重建任务的关系	2020.11.22 --2020.12.20	
3	确定毕业设计的选题，撰写开题报告	2020.12.12 --2020.12.14	
4	调研国内外相关任务的研究进展、技术路线，对研究现状进行总结，进行可行性分析	2020.12.21 --2020.12.28	
5	开题答辩和学期汇报，总结本学期研究内容，包括文献调研情况、个人取得进展、相关成果等	2020.12.29 --2021.01.10	
6	熟练掌握深度学习框架及其编程，能够利用 Pytorch 实现算法模型搭建，掌握深度学习模型的训练过程和调试方法	2021.01.11 --2021.02.18	
7	设计深度图像超分辨重建任务的核心关键问题的解决方案，借助全监督或自监督的深度估计网络进一步提高深度图像超分辨重建的精度，并编码实现、训练和调试	2021.03.01 --2021.03.31	
8	中期检查，根据检查反馈进行调整	2021.04.01 --2021.04.06	
9	模型的调试、性能对比与分析	2021.04.01 --2020.04.30	
10	毕设论文的撰写、修改	2021.03.15 --2020.04.30	
<p>指导教师意见：</p> <p>填写说明：查阅资料是否全面，提出的研究方案和计划进度是否可行，还有什么需要注意和改进的方面，是否同意按学生提出的计划进行等。（填写后请删除该说明）</p>			

指导教师（审核签名）：_____ 审核日期：_____年____月____日